

Mini Project

Amazon Sales Data Preparation for further Analysis

Presented by: Rafif Pradipta Bagaskara



About Me

Saya merupakan lulusan teknik geologi yang memiliki pengalaman dalam bidang analisis data teknis, evaluasi dan optimalisasi proses, serta manajemen operasional lintas industri (energi, manufaktur, dan logistik).

Education



Teknik Geologi (2019 - 2023)



Data Analyst (2026-Sekarang)

Experience

- Petrophysicist - PT. Elnusa Tbk.
Intern (2023)
- Production and Process Engineer -
PT. TMMIN
Intern (2024)
- Operation Officer - PT. Escorindo
Jasa Prima
Staff (2024-2025)




RAFIF PRADIPTA BAGASKARA

Table of Contents




About Dataset




Data Cleaning




Import Data



Data Manipulation




Data Exploration



Insight



Data Quality Issue



Reflection

About Dataset






Nama Kolom	Deskripsi	Tipe Data
Order ID	Kode unik identifikasi untuk setiap transaksi pemesanan	Object
Date	Tanggal terjadinya transaksi atau pemesanan produk	Object
Product	Nama produk yang dibeli oleh pelanggan	Object
Category	Kategori atau jenis produk yang dijual	Object
Price	Harga satuan produk dalam bentuk angka	Int64
Quantity	Jumlah unit produk yang dibeli dalam satu transaksi	Int64
Total Sales	Total nilai penjualan (Price × Quantity)	Int64
Customer Name	Nama pelanggan yang melakukan pembelian	Object
Customer Location	Lokasi atau wilayah tempat pelanggan berada	Object
Payment Method	Metode pembayaran yang digunakan pelanggan	Object
Status	Status transaksi atau pesanan	Object

Dataset:
Source: Kaggle
Nama Dataset: Amazon Sales 2025

Ukuran Dataset:
Jumlah Kolom: 11 Columns
Jumlah Baris: 250 Rows

Import Data



Import library yang dibutuhkan (pandas)

Load dataset dari file CSV

Memanggil df_rf.head(5) untuk melihat menampilkan datasetnya

	Order ID	Date	Product	Category	Price	Quantity	Total Sales	Customer Name	Customer Location	Payment Method	Status
0	ORD0001	14-03-25	Running Shoes	Footwear	60	3	180	Emma Clark	New York	Debit Card	Cancelled
1	ORD0002	20-03-25	Headphones	Electronics	100	4	400	Emily Johnson	San Francisco	Debit Card	Pending
2	ORD0003	15-02-25	Running Shoes	Footwear	60	2	120	John Doe	Denver	Amazon Pay	Cancelled
3	ORD0004	19-02-25	Running Shoes	Footwear	60	3	180	Olivia Wilson	Dallas	Credit Card	Pending
4	ORD0005	10-03-25	Smartwatch	Electronics	150	3	450	Emma Clark	New York	Debit Card	Pending

Data Exploration

```
===== INFO DATAFRAME =====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 250 entries, 0 to 249
Data columns (total 11 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Order ID              250 non-null   object
1   Date                  250 non-null   object
2   Product               250 non-null   object
3   Category              250 non-null   object
4   Price                 250 non-null   int64
5   Quantity              250 non-null   int64
6   Total Sales           250 non-null   int64
7   Customer Name         250 non-null   object
8   Customer Location     250 non-null   object
9   Payment Method        250 non-null   object
10  Status                250 non-null   object
dtypes: int64(3), object(8)
memory usage: 21.6+ KB
```

Untuk memahami struktur, dan isi dataset sebelum dilakukan data cleaning, preprocessing, dan analisis lebih lanjut.

Pada kolom date, tipe data belum sesuai seharusnya DateTime bukan Object

Data Exploration

	Price	Quantity	Total Sales
count	250.0	250.0	250.0
mean	343.6	2.9	975.4
std	380.6	1.4	1252.1
min	15.0	1.0	15.0
25%	40.0	2.0	100.0
50%	150.0	3.0	400.0
75%	600.0	4.0	1500.0
max	1200.0	5.0	6000.0

Analisis kolom Price:

Ditemukan bahwa $\text{mean} (343.6) > \text{median} (150)$, yang mengindikasikan adanya beberapa produk dengan harga tinggi yang menarik nilai rata-rata ke atas.

Analisis kolom Quantity:

Sebagian besar transaksi berada pada kisaran 2–4 unit dengan median 3 unit, namun terdapat transaksi hingga 5 unit, menunjukkan variasi jumlah pembelian yang tidak terlalu besar.

Analisis kolom Total Sales:

Ditemukan bahwa $\text{mean} (975.4) > \text{median} (400)$, yang menunjukkan adanya transaksi bernilai tinggi hingga 6000, sehingga data cenderung tidak berdistribusi normal dan berpotensi memiliki outlier.

Data Quality Issue



Pengecekan Kualitas Data (Data Quality Issue Checking)

1

- Validasi tipe data

Ditemukan ketidaksesuaian tipe data pada kolom Date, di mana tipe data awal masih berupa object sehingga diubah menjadi datetime agar dapat diproses sebagai data waktu.

2

- Memastikan konsistensi data

Tidak ditemukan inkonsistensi penulisan kategori pada kolom kategorikal seperti Category, Payment Method, Status, dan Customer Location.

3

- Mengidentifikasi outlier dan nilai abnormal

Ditemukan nilai ekstrem (outlier) pada kolom Total Sales, ditunjukkan oleh selisih yang cukup besar antara nilai rata-rata dan maksimum. Namun, data tetap dipertahankan karena masih merepresentasikan transaksi yang valid.

4

- Mengidentifikasi data hilang (missing value)

Tidak ditemukan missing value pada seluruh kolom dataset.

5

- Mendeteksi data duplikat

Tidak ditemukan data duplikat pada dataset.


6

- Membuat fitur tambahan untuk mendukung analisis

Dilakukan feature engineering dengan menambahkan kolom Sales Category untuk mengelompokkan transaksi menjadi High Sales dan Low Sales berdasarkan nilai median Total Sales.



Data Cleaning



```
df_rf_clean = df_rf.copy()
total_duplicate = df_rf_clean.duplicated().sum()



if total_duplicate == 0:
    print("Tidak ditemukan data duplikat pada dataset.")
else:
    print(f"Ditemukan {total_duplicate} data duplikat pada dataset.")
```

Duplicate

Output Tidak ditemukan data duplikat pada dataset.

Melakukan pengecekan ulang duplicate data untuk mengetahui apakah terdapat baris data yang sama (duplikat) pada dataset.

Data Cleaning



Missing Value



```
total_missing_value = df_rf_clean.isnull().sum().sum()

if total_missing_value == 0:
    print("Tidak ditemukan missing values pada dataset.")
else:
    print(f"Ditemukan {total_missing_value} missing values pada dataset.")
```

Output Tidak ditemukan missing values pada dataset.

Melakukan pengecekan ulang missing values untuk memastikan tidak terdapat data kosong (null values) pada dataset.

Data Cleaning




```
df_rf_clean = df_rf_clean.apply(  
    lambda col: col.str.strip() if col.dtype == "object" else col)  
  
# Validasi ulang atribut kategorikal setelah cleaning, untuk memastikan format data telah konsisten.  
for col in df_rf_clean.select_dtypes(include= "object").drop(columns="Date"):  
    print(f"\nKolom: {col}")  
    print(df_rf_clean[col].unique())
```

Inkonsistensi Data

Melakukan penanganan terhadap potensi spasi berlebih (leading/trailing spaces) pada atribut bertipe object untuk menjaga konsistensi format data, meskipun pada tahap eksplorasi tidak ditemukan inkonsistensi yang signifikan.

Data Cleaning



```
Kolom: Order ID
['ORD0001' 'ORD0002' 'ORD0003' 'ORD0004' 'ORD0005' 'ORD0006' 'ORD0007'
'ORD0008' 'ORD0009' 'ORD0010' 'ORD0011' 'ORD0012' 'ORD0013' 'ORD0014'
'ORD0015' 'ORD0016' 'ORD0017' 'ORD0018' 'ORD0019' 'ORD0020' 'ORD0021'
'ORD0022' 'ORD0023' 'ORD0024' 'ORD0025' 'ORD0026' 'ORD0027' 'ORD0028'
'ORD0029' 'ORD0030' 'ORD0031' 'ORD0032' 'ORD0033' 'ORD0034' 'ORD0035'
'ORD0036' 'ORD0037' 'ORD0038' 'ORD0039' 'ORD0040' 'ORD0041' 'ORD0042'
'ORD0043' 'ORD0044' 'ORD0045' 'ORD0046' 'ORD0047' 'ORD0048' 'ORD0049'
'ORD0050' 'ORD0051' 'ORD0052' 'ORD0053' 'ORD0054' 'ORD0055' 'ORD0056'
'ORD0057' 'ORD0058' 'ORD0059' 'ORD0060' 'ORD0061' 'ORD0062' 'ORD0063'
'ORD0064' 'ORD0065' 'ORD0066' 'ORD0067' 'ORD0068' 'ORD0069' 'ORD0070'
'ORD0071' 'ORD0072' 'ORD0073' 'ORD0074' 'ORD0075' 'ORD0076' 'ORD0077'
'ORD0078' 'ORD0079' 'ORD0080' 'ORD0081' 'ORD0082' 'ORD0083' 'ORD0084'
'ORD0085' 'ORD0086' 'ORD0087' 'ORD0088' 'ORD0089' 'ORD0090' 'ORD0091'
'ORD0092' 'ORD0093' 'ORD0094' 'ORD0095' 'ORD0096' 'ORD0097' 'ORD0098'
'ORD0099' 'ORD0100' 'ORD0101' 'ORD0102' 'ORD0103' 'ORD0104' 'ORD0105'
'ORD0106' 'ORD0107' 'ORD0108' 'ORD0109' 'ORD0110' 'ORD0111' 'ORD0112'
'ORD0113' 'ORD0114' 'ORD0115' 'ORD0116' 'ORD0117' 'ORD0118' 'ORD0119'
'ORD0120' 'ORD0121' 'ORD0122' 'ORD0123' 'ORD0124' 'ORD0125' 'ORD0126'
'ORD0127' 'ORD0128' 'ORD0129' 'ORD0130' 'ORD0131' 'ORD0132' 'ORD0133'
'ORD0134' 'ORD0135' 'ORD0136' 'ORD0137' 'ORD0138' 'ORD0139' 'ORD0140'
'ORD0141' 'ORD0142' 'ORD0143' 'ORD0144' 'ORD0145' 'ORD0146' 'ORD0147'
'ORD0148' 'ORD0149' 'ORD0150' 'ORD0151' 'ORD0152' 'ORD0153' 'ORD0154'
'ORD0155' 'ORD0156' 'ORD0157' 'ORD0158' 'ORD0159' 'ORD0160' 'ORD0161'
'ORD0162' 'ORD0163' 'ORD0164' 'ORD0165' 'ORD0166' 'ORD0167' 'ORD0168'
'ORD0169' 'ORD0170' 'ORD0171' 'ORD0172' 'ORD0173' 'ORD0174' 'ORD0175'
'ORD0176' 'ORD0177' 'ORD0178' 'ORD0179' 'ORD0180' 'ORD0181' 'ORD0182'
'ORD0183' 'ORD0184' 'ORD0185' 'ORD0186' 'ORD0187' 'ORD0188' 'ORD0189'
'ORD0190' 'ORD0191' 'ORD0192' 'ORD0193' 'ORD0194' 'ORD0195' 'ORD0196'
'ORD0197' 'ORD0198' 'ORD0199' 'ORD0200' 'ORD0201' 'ORD0202' 'ORD0203'
'ORD0204' 'ORD0205' 'ORD0206' 'ORD0207' 'ORD0208' 'ORD0209' 'ORD0210'
'ORD0211' 'ORD0212' 'ORD0213' 'ORD0214' 'ORD0215' 'ORD0216' 'ORD0217'
'ORD0218' 'ORD0219' 'ORD0220' 'ORD0221' 'ORD0222' 'ORD0223' 'ORD0224'
'ORD0225' 'ORD0226' 'ORD0227' 'ORD0228' 'ORD0229' 'ORD0230' 'ORD0231'
'ORD0232' 'ORD0233' 'ORD0234' 'ORD0235' 'ORD0236' 'ORD0237' 'ORD0238'
'ORD0239' 'ORD0240' 'ORD0241' 'ORD0242' 'ORD0243' 'ORD0244' 'ORD0245'
'ORD0246' 'ORD0247' 'ORD0248' 'ORD0249' 'ORD0250']
```

Output

```
Kolom: Product
['Running Shoes' 'Headphones' 'Smartwatch' 'T-Shirt' 'Smartphone' 'Book'
'Jeans' 'Laptop' 'Washing Machine' 'Refrigerator']

Kolom: Category
['Footwear' 'Electronics' 'Clothing' 'Books' 'Home Appliances']

Kolom: Customer Name
['Emma Clark' 'Emily Johnson' 'John Doe' 'Olivia Wilson' 'Sophia Miller'
'David Lee' 'Michael Brown' 'Daniel Harris' 'Chris White' 'Jane Smith']

Kolom: Customer Location
['New York' 'San Francisco' 'Denver' 'Dallas' 'Houston' 'Miami' 'Boston'
'Seattle' 'Los Angeles' 'Chicago']

Kolom: Payment Method
['Debit Card' 'Amazon Pay' 'Credit Card' 'PayPal' 'Gift Card']

Kolom: Status
['Cancelled' 'Pending' 'Completed']
```


Inkonsistensi Data

Data Cleaning

Deteksi Outlier


Visual & IQR

Pada dataset ini, identifikasi outlier dilakukan menggunakan metode Interquartile Range (IQR) dan visualisasi boxplot untuk melihat persebaran data pada kolom numerik utama, yaitu Price, Quantity, dan Total Sales.



- Ditemukan outlier pada kolom Total Sales, namun data tetap dipertahankan karena masih merepresentasikan transaksi yang valid.
- Nilai ekstrem pada Total Sales mencerminkan adanya transaksi dengan nilai penjualan tinggi, sehingga bukan merupakan kesalahan input data.

Data Cleaning



Outlier Labeling




Memberikan label (flagging) pada data yang terindikasi sebagai outlier berdasarkan metode IQR pada atribut "Total Sales".

	Order ID	Date	Product	Category	Price	Quantity	Total Sales	Customer Name	Customer Location	Payment Method	Status	Is Outlier
21	ORD0022	07-03-25	Refrigerator	Home Appliances	1200	4	4800	Olivia Wilson	Houston	Credit Card	Pending	True
61	ORD0062	10-02-25	Laptop	Electronics	800	5	4000	Olivia Wilson	San Francisco	PayPal	Completed	True
63	ORD0064	13-02-25	Refrigerator	Home Appliances	1200	4	4800	Emily Johnson	Denver	PayPal	Pending	True
68	ORD0069	25-02-25	Refrigerator	Home Appliances	1200	4	4800	David Lee	Boston	Gift Card	Pending	True
73	ORD0074	25-03-25	Refrigerator	Home Appliances	1200	4	4800	Jane Smith	Dallas	Gift Card	Cancelled	True
92	ORD0093	06-03-25	Refrigerator	Home Appliances	1200	5	6000	David Lee	Denver	PayPal	Cancelled	True
119	ORD0120	16-02-25	Laptop	Electronics	800	5	4000	Emily Johnson	Denver	PayPal	Completed	True
125	ORD0126	04-02-25	Refrigerator	Home Appliances	1200	5	6000	Olivia Wilson	Chicago	Gift Card	Pending	True
154	ORD0155	05-02-25	Refrigerator	Home Appliances	1200	4	4800	Sophia Miller	Seattle	Credit Card	Pending	True
167	ORD0168	24-03-25	Laptop	Electronics	800	5	4000	Michael Brown	Miami	Debit Card	Pending	True
230	ORD0231	16-02-25	Laptop	Electronics	800	5	4000	Jane Smith	Boston	Credit Card	Cancelled	True

```
df_rf_clean["Is Outlier"] = (df_rf_clean["Total Sales"] < lower) | (df_rf_clean["Total Sales"] > upper)
```

```
# Menampilkan data yang terindikasi sebagai outlier
df_rf_clean[df_rf_clean["Is Outlier"]]
```


Data Manipulation



Uji Transformasi Data

Transformasi dilakukan pada kolom Price, Quantity, dan Total Sales untuk melihat apakah distribusi data dapat menjadi lebih normal.

Metode yang diuji:

- Square Root → mengurangi skewness ringan
- Log Transformation → mengurangi pengaruh outlier
- Box-Cox → mencari transformasi optimal

Interpretasi Shapiro-Wilk Test:

- $p\text{-value} > 0.05 \rightarrow$ data normal
- $p\text{-value} \leq 0.05 \rightarrow$ data tidak normal

Insight:

- Hasil uji menunjukkan distribusi data masih cenderung tidak normal, meskipun telah dilakukan transformasi menggunakan Square Root, Log, dan Box-Cox.


Data Manipulation



```
df_rf_manipulation = df_rf_clean.copy()

df_rf_manipulation["Date"] = pd.to_datetime(df_rf_manipulation["Date"], format="%d-%m-%y", errors="coerce")
df_rf_manipulation.head(10)
```

	Order ID	Date
0	ORD0001	14-03-25
1	ORD0002	20-03-25
2	ORD0003	15-02-25
3	ORD0004	19-02-25
4	ORD0005	10-03-25
5	ORD0006	14-03-25
6	ORD0007	18-03-25
7	ORD0008	02-03-25
8	ORD0009	08-03-25
9	ORD0010	12-03-25



	Order ID	Date
0	ORD0001	2025-03-14
1	ORD0002	2025-03-20
2	ORD0003	2025-02-15
3	ORD0004	2025-02-19
4	ORD0005	2025-03-10
5	ORD0006	2025-03-14
6	ORD0007	2025-03-18
7	ORD0008	2025-03-02
8	ORD0009	2025-03-08
9	ORD0010	2025-03-12

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 250 entries, 0 to 249
Data columns (total 12 columns):
 #   Column                Non-Null Count  Dtype
---  -
 0   Order ID              250 non-null   object
 1   Date                  250 non-null   datetime64[ns]
 2   Product               250 non-null   object
 3   Category              250 non-null   object
 4   Price                 250 non-null   int64
 5   Quantity              250 non-null   int64
 6   Total Sales           250 non-null   int64
 7   Customer Name         250 non-null   object
 8   Customer Location     250 non-null   object
 9   Payment Method        250 non-null   object
10   Status                250 non-null   object
11   Is Outlier            250 non-null   bool
dtypes: bool(1), datetime64[ns](1), int64(3), object(7)
memory usage: 21.9+ KB
```

Data Manipulation

```
# Membuat dataset baru agar data asli tetap aman dan tidak berubah
df_rf_manipulation2 = (df_rf_manipulation.copy())

# Membuat kategori penjualan berdasarkan nilai median Total Sales
# > median = High Sales
# <= median = Low Sales
df_rf_manipulation2["Sales Category"] = df_rf_manipulation2["Total Sales"].apply(
    lambda x: "High Sales" if x > median_total_sales else "Low Sales")

# Menampilkan 5 data pertama setelah penambahan kolom baru
df_rf_manipulation2.head(5)
```

Feature engineering dilakukan untuk mengelompokkan transaksi berdasarkan nilai Total Sales menjadi kategori penjualan tinggi dan rendah.

Penambahan kolom Sales Category

	Order ID	Date	Product	Category	Price	Quantity	Total Sales	Customer Name	Customer Location	Payment Method	Status	Is Outlier	Sales Category
0	ORD0001	2025-03-14	Running Shoes	Footwear	60	3	180	Emma Clark	New York	Debit Card	Cancelled	False	Low Sales
1	ORD0002	2025-03-20	Headphones	Electronics	100	4	400	Emily Johnson	San Francisco	Debit Card	Pending	False	Low Sales
2	ORD0003	2025-02-15	Running Shoes	Footwear	60	2	120	John Doe	Denver	Amazon Pay	Cancelled	False	Low Sales
3	ORD0004	2025-02-19	Running Shoes	Footwear	60	3	180	Olivia Wilson	Dallas	Credit Card	Pending	False	Low Sales
4	ORD0005	2025-03-10	Smartwatch	Electronics	150	3	450	Emma Clark	New York	Debit Card	Pending	False	High Sales

Data Manipulation

Encoding Kolom Kategorikal

One Hot Encoding

Untuk kolom: **Category, Payment Method, dan Status**

Digunakan pada kolom dengan jumlah kategori relatif sedikit dan tidak memiliki urutan tertentu.

Metode ini membuat kolom baru untuk setiap kategori sehingga seluruh kategori dianggap setara tanpa adanya hubungan ranking atau tingkatan.

Binary Encoding

Untuk kolom: **Order ID dan Customer Location**

Digunakan pada kolom dengan jumlah kategori unik yang cukup banyak.

Metode ini mengubah kategori menjadi representasi kode biner, sehingga lebih efisien dibandingkan One Hot Encoding dan tidak membuat jumlah kolom bertambah terlalu banyak.

Label Encoding

Untuk kolom: **Customer Name, Is Outlier, dan Sales Category**

Digunakan untuk mengubah data kategorikal menjadi bentuk numerik.

Pada kolom Is Outlier dan Sales Category, metode ini digunakan karena hanya memiliki dua kategori (binary category). Sedangkan pada Customer Name, encoding dilakukan agar data dapat diproses dalam bentuk numerik.

Frequency Encoding

Untuk kolom: **Product**

Digunakan pada kolom dengan jumlah kategori yang cukup banyak (high cardinality).

Metode ini mengubah setiap kategori menjadi nilai berdasarkan frekuensi kemunculannya, sehingga jumlah kolom tetap efisien tanpa membuat dataset terlalu besar, sekaligus mempertahankan informasi terkait frekuensi produk dalam transaksi.

Data Manipulation

Encoding Kolom Kategorikal

Before

	Order ID	Date	Product	Category	Price	Quantity	Total Sales	Customer Name	Customer Location	Payment Method	Status	Is Outlier	Sales Category
0	ORD0001	2025-03-14	Running Shoes	Footwear	60	3	180	Emma Clark	New York	Debit Card	Cancelled	False	Low Sales
1	ORD0002	2025-03-20	Headphones	Electronics	100	4	400	Emily Johnson	San Francisco	Debit Card	Pending	False	Low Sales
2	ORD0003	2025-02-15	Running Shoes	Footwear	60	2	120	John Doe	Denver	Amazon Pay	Cancelled	False	Low Sales
3	ORD0004	2025-02-19	Running Shoes	Footwear	60	3	180	Olivia Wilson	Dallas	Credit Card	Pending	False	Low Sales
4	ORD0005	2025-03-10	Smartwatch	Electronics	150	3	450	Emma Clark	New York	Debit Card	Pending	False	High Sales



After

	Order ID_0	Order ID_1	Order ID_2	Order ID_3	Order ID_4	Order ID_5	Order ID_6	Order ID_7	Date	Product	...	Category_Footwear	Category_Home Appliances	Payment Method_Amazon Pay	Payment Method_Credit Card	Payment Method_Debit Card	Payment Method_Gift Card	Payment Method_PayPal	Status_Cancelled	Status_Completed	Status_Pending
0	0	0	0	0	0	0	0	1	2025-03-14	0.108	...	True	False	False	False	True	False	False	True	False	False
1	0	0	0	0	0	0	1	0	2025-03-20	0.100	...	False	False	False	False	True	False	False	False	False	True
2	0	0	0	0	0	0	1	1	2025-02-15	0.108	...	True	False	True	False	False	False	False	True	False	False

Insight

Status Transaksi

Sebagian besar transaksi berada pada status non-completed (64.80%), sedangkan transaksi completed hanya 35.20%. Hal ini menunjukkan masih banyak transaksi yang belum berhasil diselesaikan, sehingga analisis penjualan aktual lebih difokuskan pada transaksi completed.

Jumlah transaksi completed: 88 dari 250 transaksi (35.20%)

Jumlah transaksi non-completed: 162 dari 250 transaksi (64.80%)



High-Value Transactions

Ditemukan 121 transaksi dengan penjualan tinggi, menunjukkan adanya transaksi bernilai besar yang memberikan kontribusi signifikan terhadap total pendapatan. Namun, hanya 46 transaksi completed yang memiliki nilai penjualan di atas median (400), menandakan tidak semua transaksi bernilai besar berhasil dikonversi menjadi penjualan aktual.

Jumlah transaksi dengan penjualan tinggi: 121

Ditemukan 46 transaksi berstatus 'Completed' dengan penjualan di atas nilai median (400).

Insight

Kontribusi Category terhadap Penjualan

Kategori Electronics memberikan kontribusi terbesar terhadap total penjualan (53.29%) dan meningkat menjadi 63.14% pada transaksi completed. Hal ini menunjukkan bahwa produk elektronik menjadi sumber pendapatan utama sekaligus memiliki tingkat penyelesaian transaksi yang lebih tinggi.

Sementara itu, kategori Books, Clothing, dan Footwear memiliki kontribusi yang relatif kecil (<2%) terhadap total penjualan.



Category	
Electronics	53.29
Home Appliances	43.06
Footwear	1.77
Clothing	1.45
Books	0.42
Name: Total Sales, dtype: float64	

kontribusi penjualan tiap kategori produk

Category	
Electronics	63.14
Home Appliances	33.21
Footwear	1.83
Clothing	1.58
Books	0.24
Name: Total Sales, dtype: float64	

kontribusi penjualan kategori produk pada transaksi completed

Reflection

- Proses persiapan menunjukkan bahwa data transaksi nyata sering kali memerlukan beberapa tahapan preprocessing sebelum dapat digunakan untuk analisis yang lebih mendalam. Selama proses ini, ditemukan beberapa tantangan seperti tipe data yang belum sesuai, distribusi data yang tidak merata, serta adanya nilai ekstrem (outlier) pada kolom Total Sales.
- Penanganan data dilakukan dengan mempertimbangkan keseimbangan antara integritas data dan kebutuhan analisis. Tidak seluruh data ekstrem dihapus, karena nilai transaksi tinggi masih mencerminkan kondisi riil pada platform e-commerce dan berpotensi memberikan insight penting terhadap pola pembelian pelanggan.
- Tahap feature engineering berhasil menambahkan dimensi analisis baru, seperti pengelompokan transaksi berdasarkan Sales Category (High Sales & Low Sales) serta identifikasi outlier, sehingga membantu memahami pola transaksi secara lebih baik. Selain itu, proses encoding kategorikal juga membuat dataset lebih siap untuk analisis lanjutan karena seluruh variabel telah berhasil dikonversi ke format numerik.
- Secara keseluruhan, proses ini menegaskan pentingnya pemahaman data, asumsi yang jelas, serta dokumentasi preprocessing dalam menghasilkan dataset yang lebih siap digunakan untuk analisis maupun pemodelan selanjutnya.

Thank You

Questions are welcome

RAFIF PRADIPTA BAGASKARA



<https://canva.link/as3i3qx0zeizx9j>